交付格式

一、交付目录结构

供应商应将音频文件与标注文件解耦，建议采用以下层级结构：

复制代码

```
source_a/                              # 默认值
  │
  └── ds_20260320/                     # 日期分区
        ├ shanghaihua/ （客家用hakka）     # 方言类型
        │   ├── audio/                 # 存放所有音频文件
        │   │   ├── sample001.wav
        │   │   ├── sample002.wav
        │   ├── shanghaihua_metadata_1.jsonl            # 核心标注文件（全文仅此一个或每个子文件夹一个
        │   ├── shanghaihua_metadata_2.jsonl            # 核心标注文件备份，序号用2
        │   └── shanghaihua_dataset_info.json         # 数据集元数据（可选，记录语言、采样率、总时长等）
        ├ shanxi_dialect/      # 方言类型
        │   ├── audio/                 # 存放所有音频文件
        │   │   ├── sample001.wav
        │   │   ├── sample002.wav
        │   ├── shanxi_dialect_metadata_1.jsonl   # 核心标注文件（全文仅此一个或每个子文件夹一个
        │   └── shanxi_dialect_dataset_info.json      # 数据集元数据（可选，记录语言、采样率、总时长等）
        ├ ...     # 方言类型

        ├── 其它文件          #数据集其它信息 （可选，比如标注数据的原始信息等，供应商交互数据自行定义补充）
```

标注文件格式 (JSONL)

metadata.jsonl必须采用 JSONL (UTF-8 编码) 格式。每一行代表一个完整的音频文件及其对应的所有标注信息。

字段名	类型	必填	说明
`audio_id`	String	是	音频唯一标识符（用音频的md5值）
`audio_path`	String	是	音频文件的相对路径， 例如 `audio/folder_01/sample001.wav`
`duration`	Float	是	音频总时长，单位：秒（保留3位小数）
`segments`	Array[Object]	是	切分片段列表（用于长音频或多句语音）

其中，segments内部字段定义如下：

字段名	类型	必填	说明
`segment_id`	Int/Str	否	片段序号
`start_time`	Float	**是**	片段开始时间，单位：秒（保留3位小数）
`end_time`	Float	**是**	片段结束时间，单位：秒（保留3位小数）
`raw_transcript`	**String**	**是**	**有效语音数据**，该片段对应的原始标注文本 字、标点、**以及任何特殊符号**。 • 特殊符号举例：<noise> <music> <bg 际意义的特殊标签信息。 特殊标签各家 不一样，以上仅仅做参考。
`transcript`	String	**是**	**有效语音数据**，该片段对应的 `raw_transc` **理之后的**转写文本，**不能有除了文字和正常 任何特殊标签符号**。 • 特殊符号：比如<noise> <music> /SIL 特殊标签，需要去除。 特殊标签各家定 一样，以上仅仅做参考。 • **注意：除标点外的很多符号，并不一定 的特殊符号，处理人员应给予额外关注** ◦ 货币符号：¥,$,€,£,₩ ◦ 数学符号：%,‰,:,√,∞,π,±,+,-,×, ◦ 物理符号：°,°C,°F,㎡,㎥,μ,Ω,ℓ ◦ 商业符号：@,#,&,*,©,®,™, ◦ 希腊字母：α,β,γ,Δ,λ,ω ◦ 其他符号：·(外国人名中间),《,》
`speaker_id`	String	否	说话人 ID（**多角色对话场景必填**）
`standardized_text`	String	否	方言的标准书面语翻译文本民主要针对方言
`extra_info`	Object	否	与该片段相关的其他信息，如说话人性别， 信息，~~带有特殊符号的转写文本（例如[nois <>）等~~。

标注文件metadata.jsonl示例

metadata.jsonl 复制代码

{"audio_id": "sample001", "audio_path": "audio/folder_01/sample001.wav", "duration": 5.200, "segments": [{"start_time": 0.200, "end_time": 4.800, "transcript": "前往北京的机票多少钱？"}]}
{"audio_id": "sample002", "audio_path": "audio/folder_01/sample002.wav", "duration": 12.450, "segments": [{"segment_id": 1, "start_time": 0.500, "end_time": 3.200, "transcript": "你好，今天天气不错。", "speaker_id": "SPK001", "extra_info": {"language": "普通话", "gender": "male"}}, {"segment_id": 2, "start_time": 4.100, "end_time": 11.800, "transcript": "是的，非常适合郊游。", "speaker_id": "SPK002", "extra_info": {"language": "普通话", "gender": "female"}}]}
{"audio_id": "sample003", "audio_path": "audio/folder_02/sample003.wav", "duration": 2.600, "segments": [{"start_time": 0.400, "end_time": 2.400, "transcript": "点解会咁样？", "standardized_text": "为什么会这样？", "extra_info": {"language": "粤语"}}]}

metadata.jsonl (formatted, 仅用于展示结构) 复制代码


```
{
    "audio_id": "sample001",
    "audio_path": "audio/folder_01/sample001.wav",
    "duration": 5.200,
    "segments": [
        {
            "start_time": 0.200,
            "end_time": 4.800,
            "transcript": "前往北京的机票多少钱？"
        }
    ]
}
{
    "audio_id": "sample002",
    "audio_path": "audio/folder_01/sample002.wav",
    "duration": 12.450,
    "segments": [
        {
            "segment_id": 1,
            "start_time": 0.500,
            "end_time": 3.200,
            "transcript": "你好，今天天气不错。",
            "speaker_id": "SPK001",
            "extra_info": {
                "language": "普通话",
                "gender": "male"
            }
        },
        {
            "segment_id": 2,
            "start_time": 4.100,
            "end_time": 11.800,
            "transcript": "是的，非常适合郊游。",
            "speaker_id": "SPK002",
            "extra_info": {
                "language": "普通话",
                "gender": "female"
            }
        }
    ]
}
{
    "audio_id": "sample003",
    "audio_path": "audio/folder_02/sample003.wav",
    "duration": 2.600,
    "segments": [
        {
```

```
            "start_time": 0.400,
            "end_time": 2.400,
            "transcript": "点解会咁样？",
            "standardized_text": "为什么会这样？",
            "extra_info": {
                "language": "粤语"
            }
        }
    ]
}
```

音频格式规范

为了保证模型训练效果，交付的音频需满足以下技术要求：

- 格式： 优先采用无损 `.wav` 格式（PCM编码）。
- 采样率： 16,000 Hz 或更高。
- 位深： 16-bit或更高。
- **音频切分： segments中单个音频切片长度不超过1分钟，且首尾静音控制在 100ms-500ms 之间。**

校验准则（供应商自检）

在交付前，供应商需运行自检脚本确保满足以下条件：

- JSONL 格式正确： 每一行必须是一个合法的 JSON 对象。
- 路径一致性： `audio_path` 指向的文件在目录中必须存在。
- 时长匹配： 标注的 `duration` 与 `segments` 的 `end_time` 不得超过音频实际长度。
- 逻辑自洽： `start_time` 必须小于 `end_time`。
- 字符编码： 必须为 UTF-8 无 BOM 格式，不得含有非法乱码。